



МИНОБРНАУКИ РОССИИ

Федеральное государственное бюджетное образовательное учреждение
высшего образования
«МИРЭА – Российский технологический университет»
РТУ МИРЭА

КУРСОВАЯ РАБОТА

по дисциплине

Прогнозно-аналитические системы

Тема курсовой работы:

«Разработка сценария анализа и обработки данных на примере задачи оттока
клиентов банка с применением логистической модели»

Выполнил студент группы ИМБО-02-22

Ким Кирилл Сергеевич

Руководитель курсовой работы

Юрченков Иван Александрович



Введение

Цель: разработать сценарии анализа и обработать данные для прогнозирования оттока клиентов банка с использованием логистической регрессии.

Задачи:

- Исследовать данные о клиентах банка и выявить факторы, влияющие на отток
- Провести предобработку данных и создать новые признаки
- Построить и оценить модель логистической регрессии
- Проанализировать важность признаков и сделать выводы
- Разработать систему скоринга для сегментации клиентов по риску оттока
- Предложить практические рекомендации для банка

Логистическая регрессия



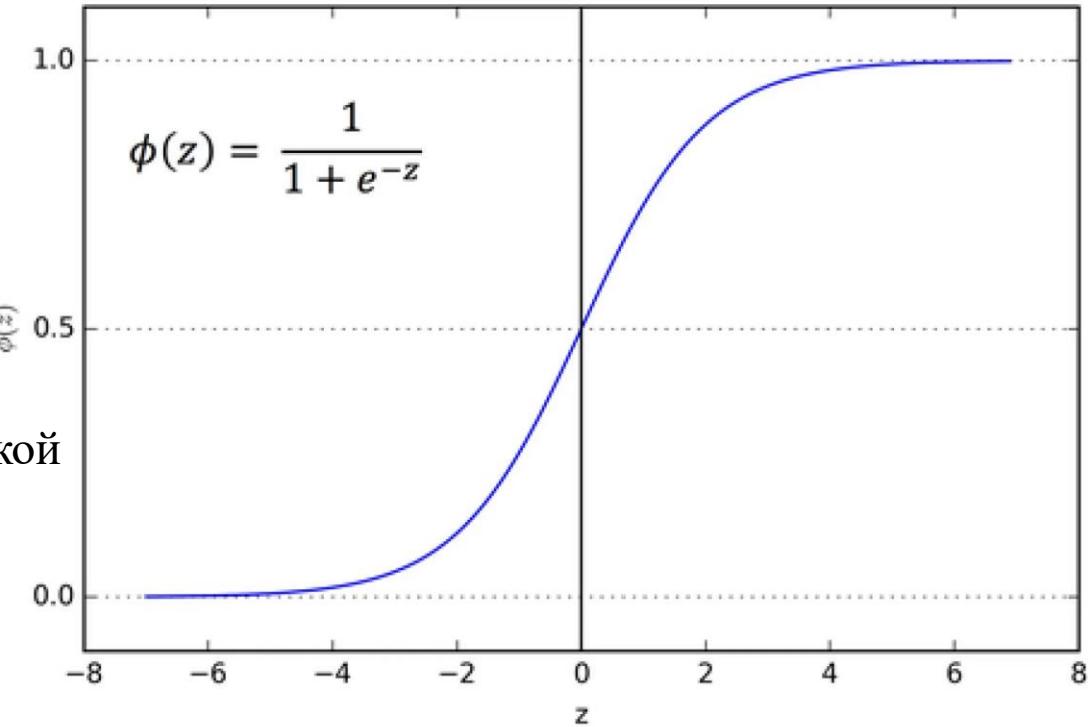
$$f(z) = \frac{1}{1 + e^{-z}},$$

где $z = \theta^T x$,

θ — вектор-столбец параметров (весов) логистической регрессии,

x — вектор-столбец независимых переменных.

Логистическая функция преобразует линейную комбинацию в вероятность принадлежности к целевому классу, принимающую значения в диапазоне от 0 до 1.





Функция потерь (Log loss)

Формула для правдоподобия:

$$\prod p_i^{y_i} (1 - p_i)^{1-y_i} \rightarrow \max$$

где p_i — вероятность принадлежности к целевому классу i -ого объекта,

y_i — целевое значение i -ого объекта.

Log loss:

$$-\frac{1}{n} \sum (y_i * \log(p_i) + (1 - y_i) * \log(1 - p_i)) \rightarrow \min$$

где p_i — вероятность принадлежности к целевому классу i -ого объекта,

y_i — целевое значение i -ого объекта,
n — количество объектов.



Метрики качества

$$Accuracy = \frac{TP + TN}{TP + TN + FP + FN}$$

$$Precision = \frac{TP}{TP+FP}.$$

$$Recall = \frac{TP}{TP+FN}.$$

$$F1 = 2 * \frac{precision*recall}{precision+recall}.$$

Кривая *ROC* — это график, который иллюстрирует производительность классификационной модели при всех возможных порогах классификации. Ось X данного графика представляет собой *FPR*, т.е. ложноположительную частоту, а ось Y — *TPR*.

$$TPR = \frac{TP}{TP+FN},$$

$$FPR = \frac{FP}{TN+FP}.$$

Чтобы агрегировать эту кривую в скаляр вычисляется площадь под этой кривой.

		Predicted 0	Predicted 1
Actual 0	0	TN	FP
	1	FN	TP

TP — количество действительно положительных объектов;

TN — количество действительно отрицательных объектов;

FP — количество ложноположительных объектов;

FN — количество ложноотрицательных объектов.



Описание признаков

Тип данных	Поле	Описание поля
целочисленный	RowNumber, CustomerId, Surname	Идентификация
целочисленный	CreditScore	Кредитный рейтинг
строковый	Geography	Страна клиента
строковый	Gender	Пол
целочисленный	Age	Возраст
целочисленный	Tenure	Сколько лет клиент с банком сотрудничает
вещественный	Balance	Баланс
целочисленный	IsActiveMember	Активность (0/1)
целочисленный	Exited	Целевая переменная (0 — остался, 1 — ушёл).



Данные

RowNumber	CustomerId	Surname	CreditScore	Geography	Gender	Age	Tenure	Balance	NumOfProducts	HasCrCard	IsActiveMember	EstimatedSalary	Exited	
0	1	15634602	Hargrave	619	France	Female	42	2	0.00	1	1	1	101348.88	1
1	2	15647311	Hill	608	Spain	Female	41	1	83807.86	1	0	1	112542.58	0
2	3	15619304	Onio	502	France	Female	42	8	159660.80	3	1	0	113931.57	1
3	4	15701354	Boni	699	France	Female	39	1	0.00	2	0	0	93826.63	0
4	5	15737888	Mitchell	850	Spain	Female	43	2	125510.82	1	1	1	79084.10	0

Данные

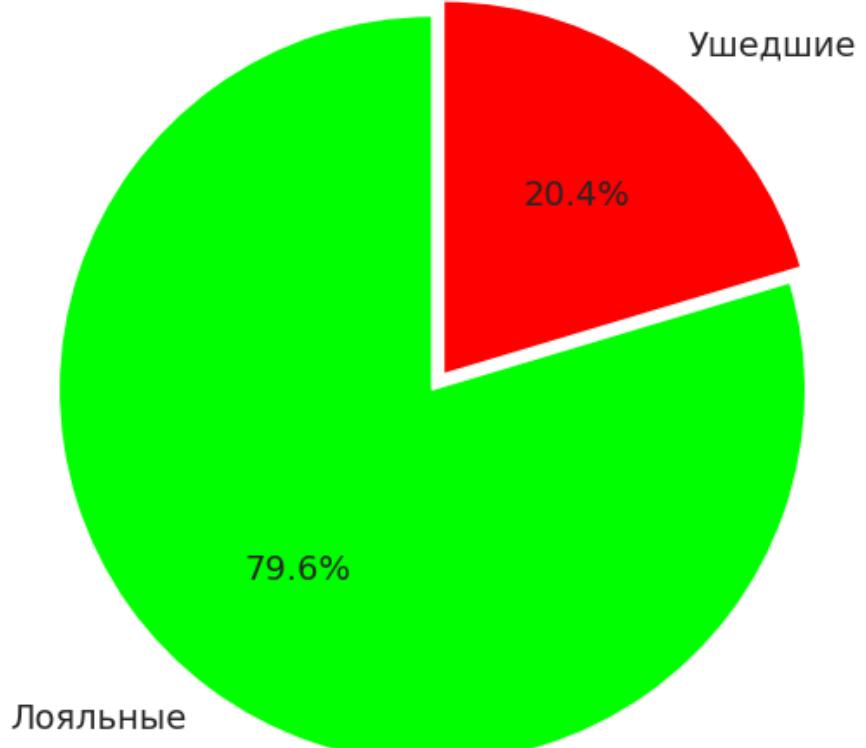
	CreditScore	Gender	Age	Tenure	Balance	NumOfProducts	HasCrCard	IsActiveMember	EstimatedSalary	Exited
7	376	0	29	4	115046.74	4	1	0	119346.88	1
15	616	1	45	3	143129.41	2	0	1	64327.26	0
16	653	1	58	1	132602.88	1	1	0	5097.67	1
26	756	1	36	2	136815.64	1	1	1	170041.95	0
28	574	0	43	3	141349.43	1	1	1	100187.43	0

Предобработанные данные

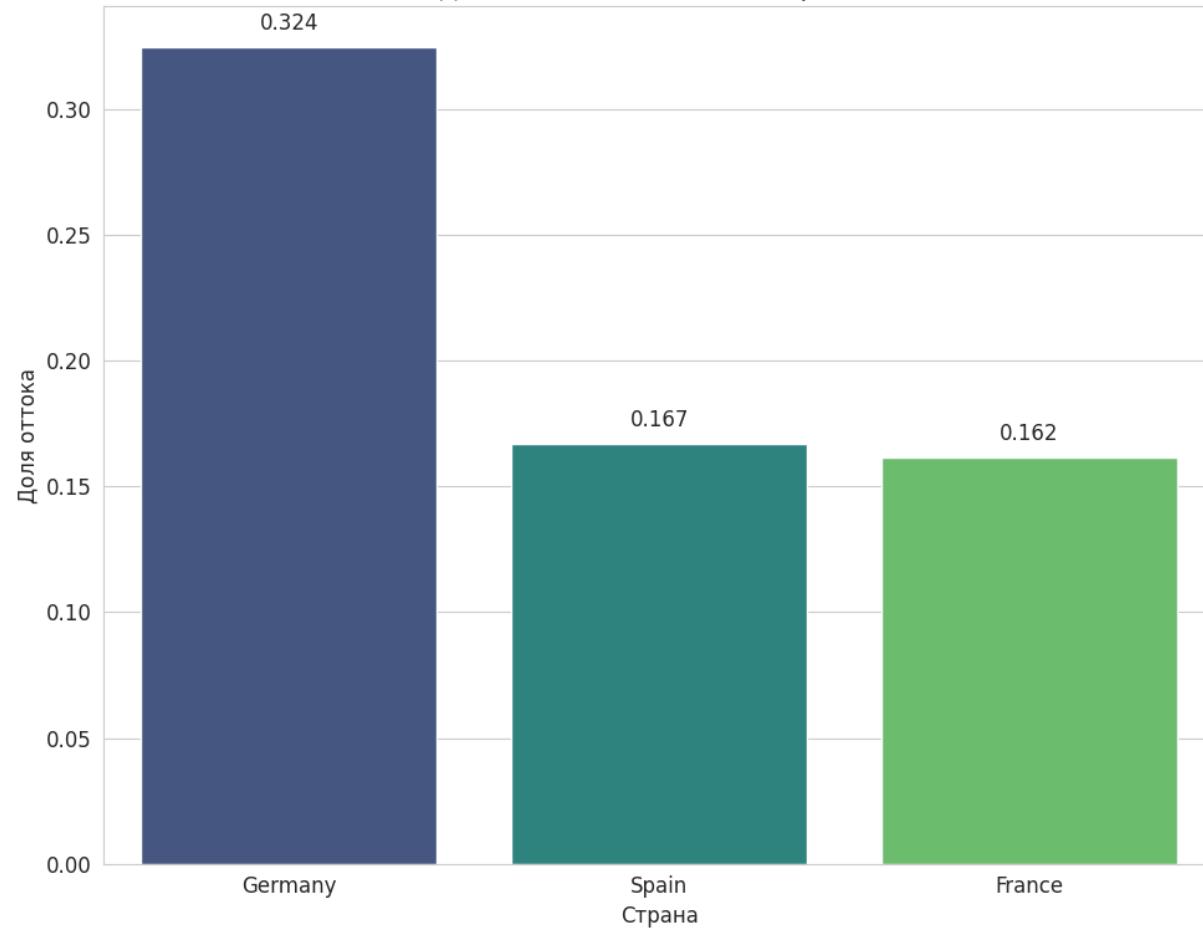


Распределение признаков

Распределение клиентов по оттоку



Доля оттока клиентов по странам





Модель классификации

Accuracy: 0.6707

Precision: 0.4936

Recall: 0.6352

F1: 0.5556

ROC-AUC: 0.7198

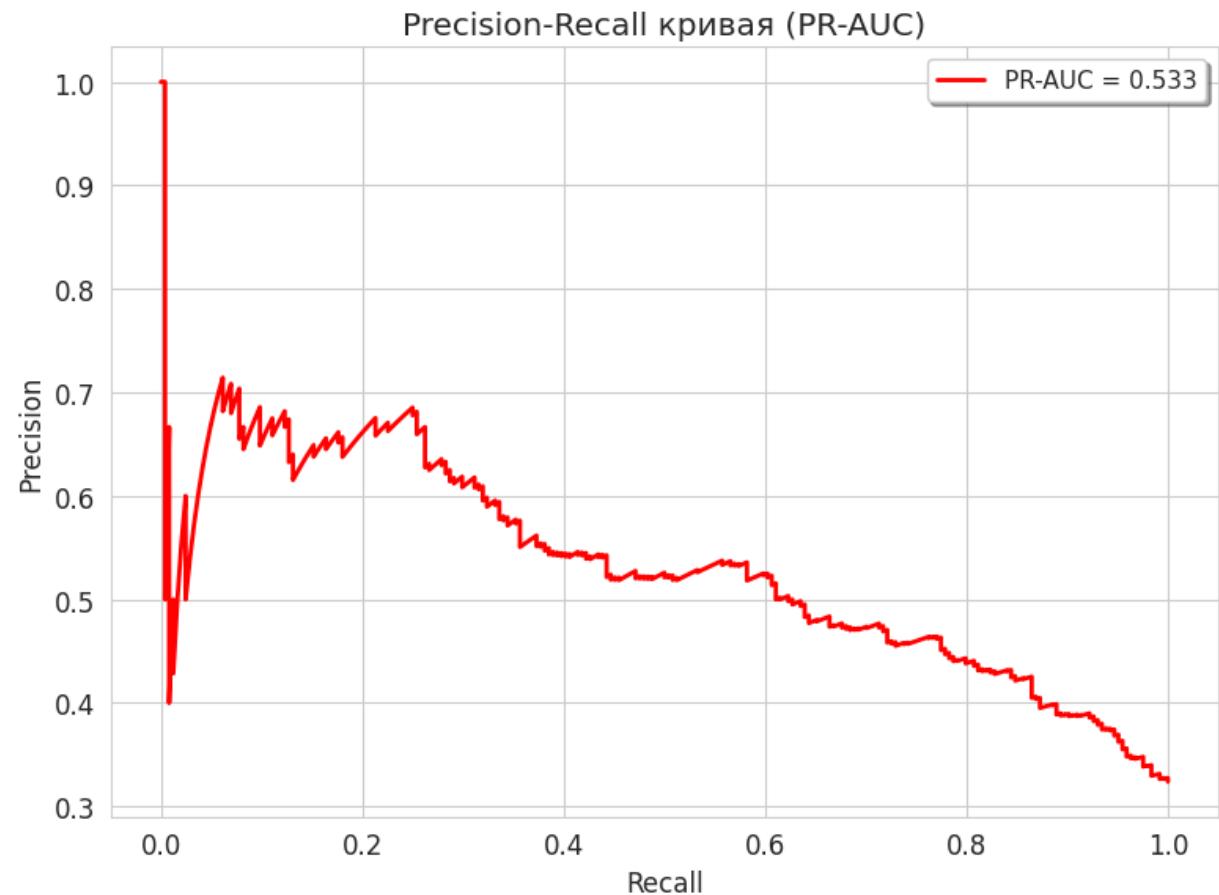
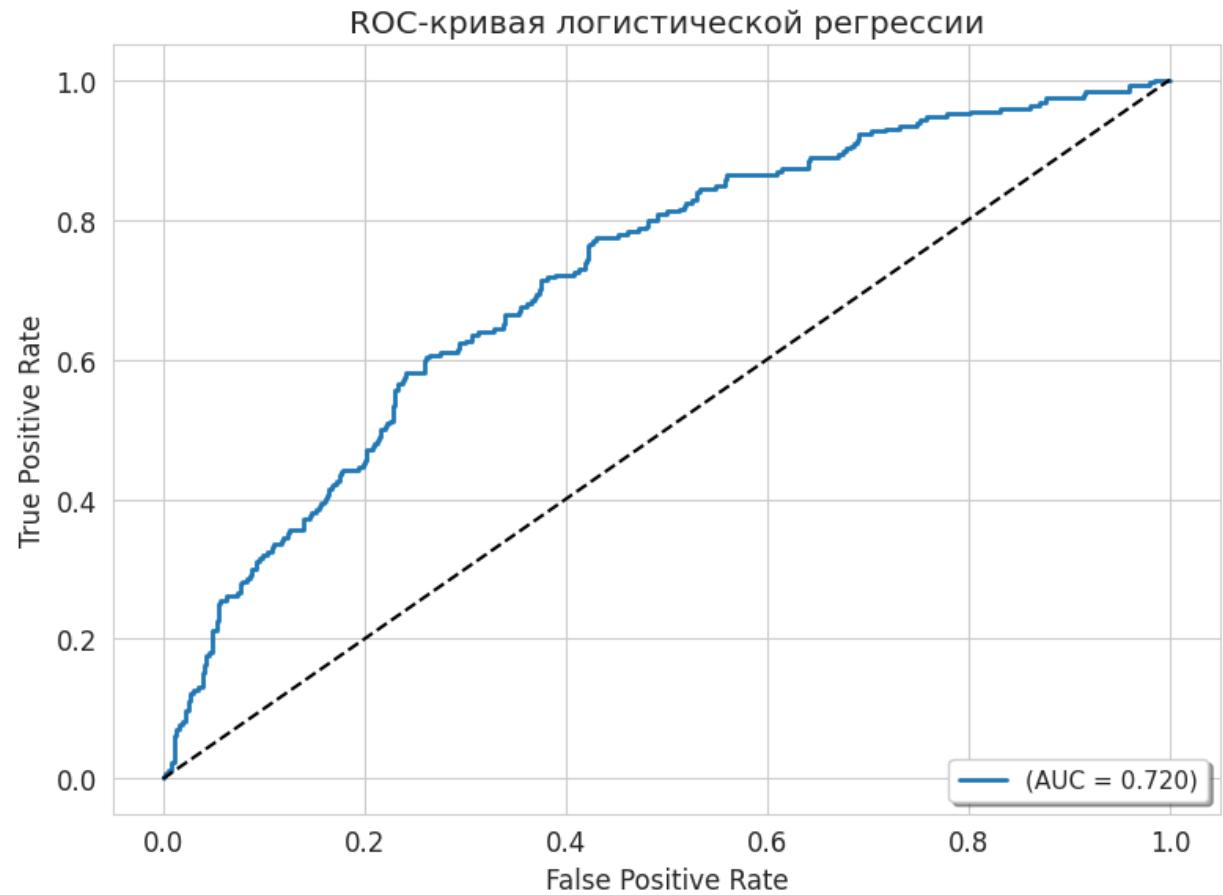
PR-AUC: 0.5330

Логарифмическая функция потерь: 0.6139





Визуализация

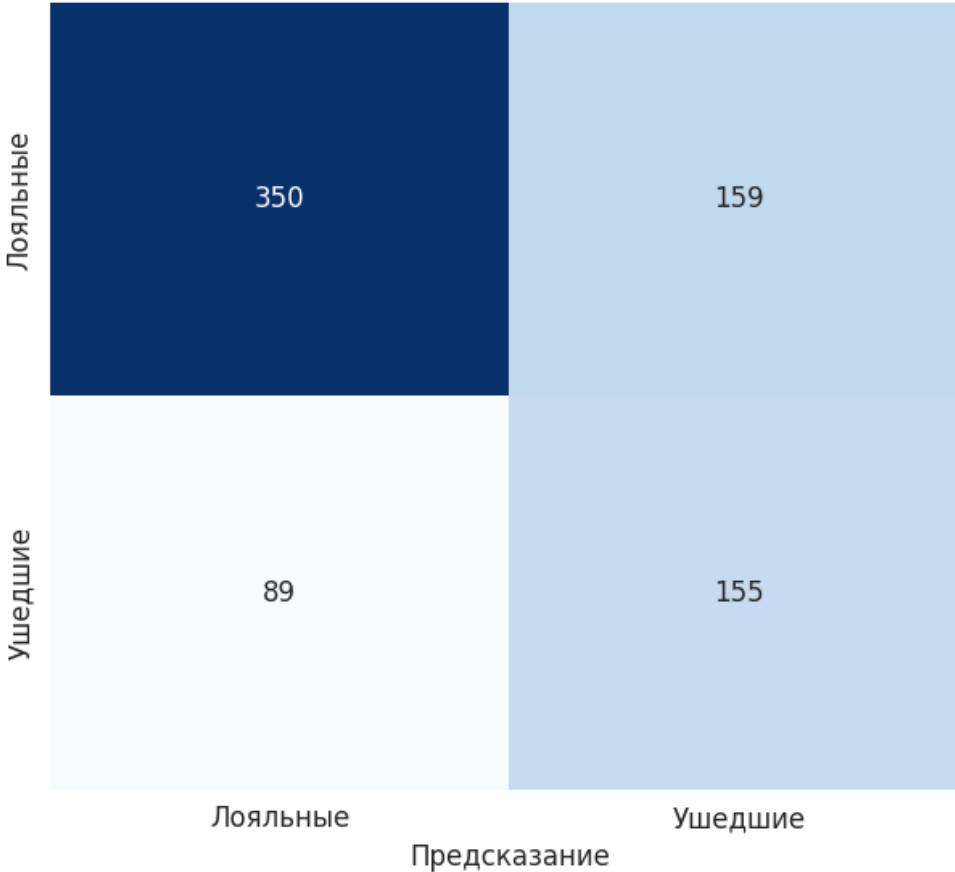




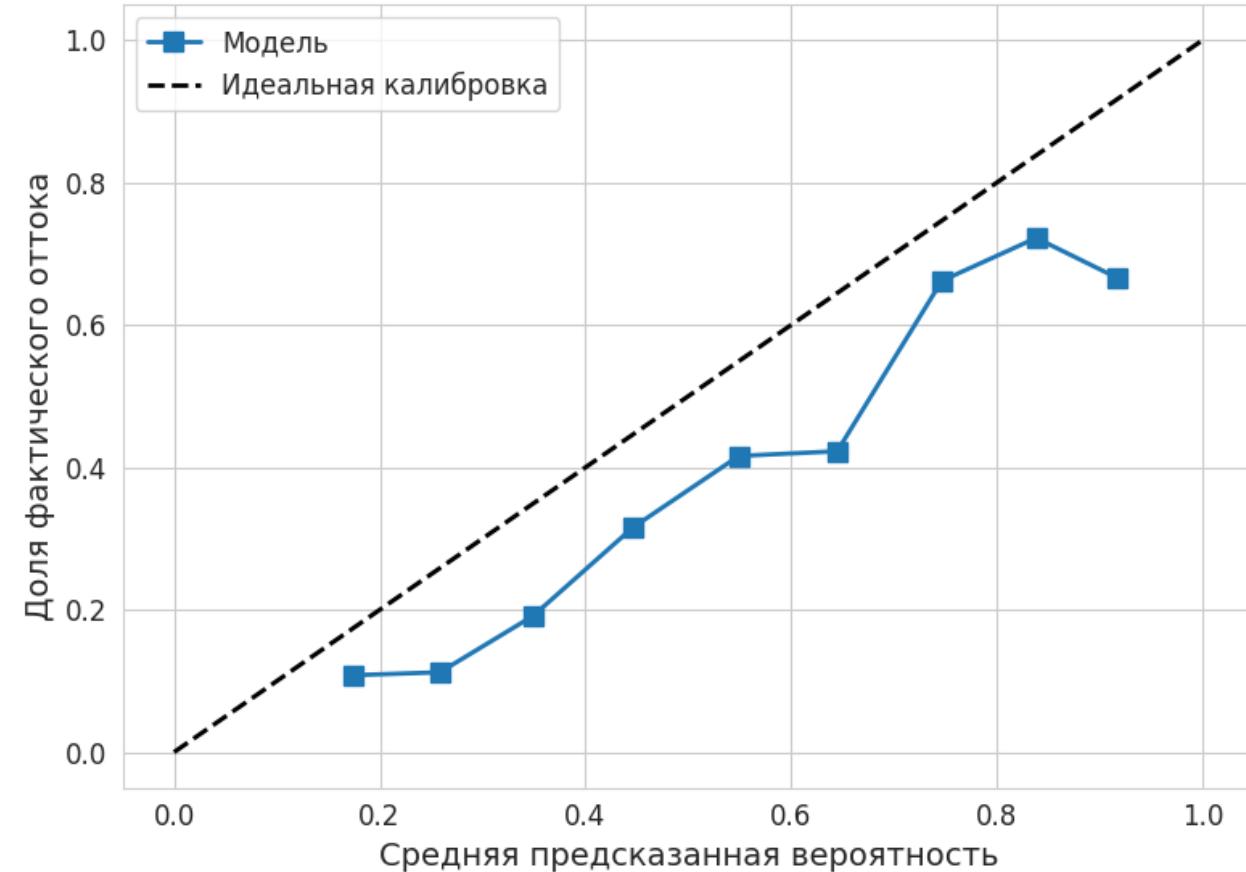
Визуализация

Матрица ошибок логистической регрессии

Факт



Калибровка вероятностей





Система скоринга

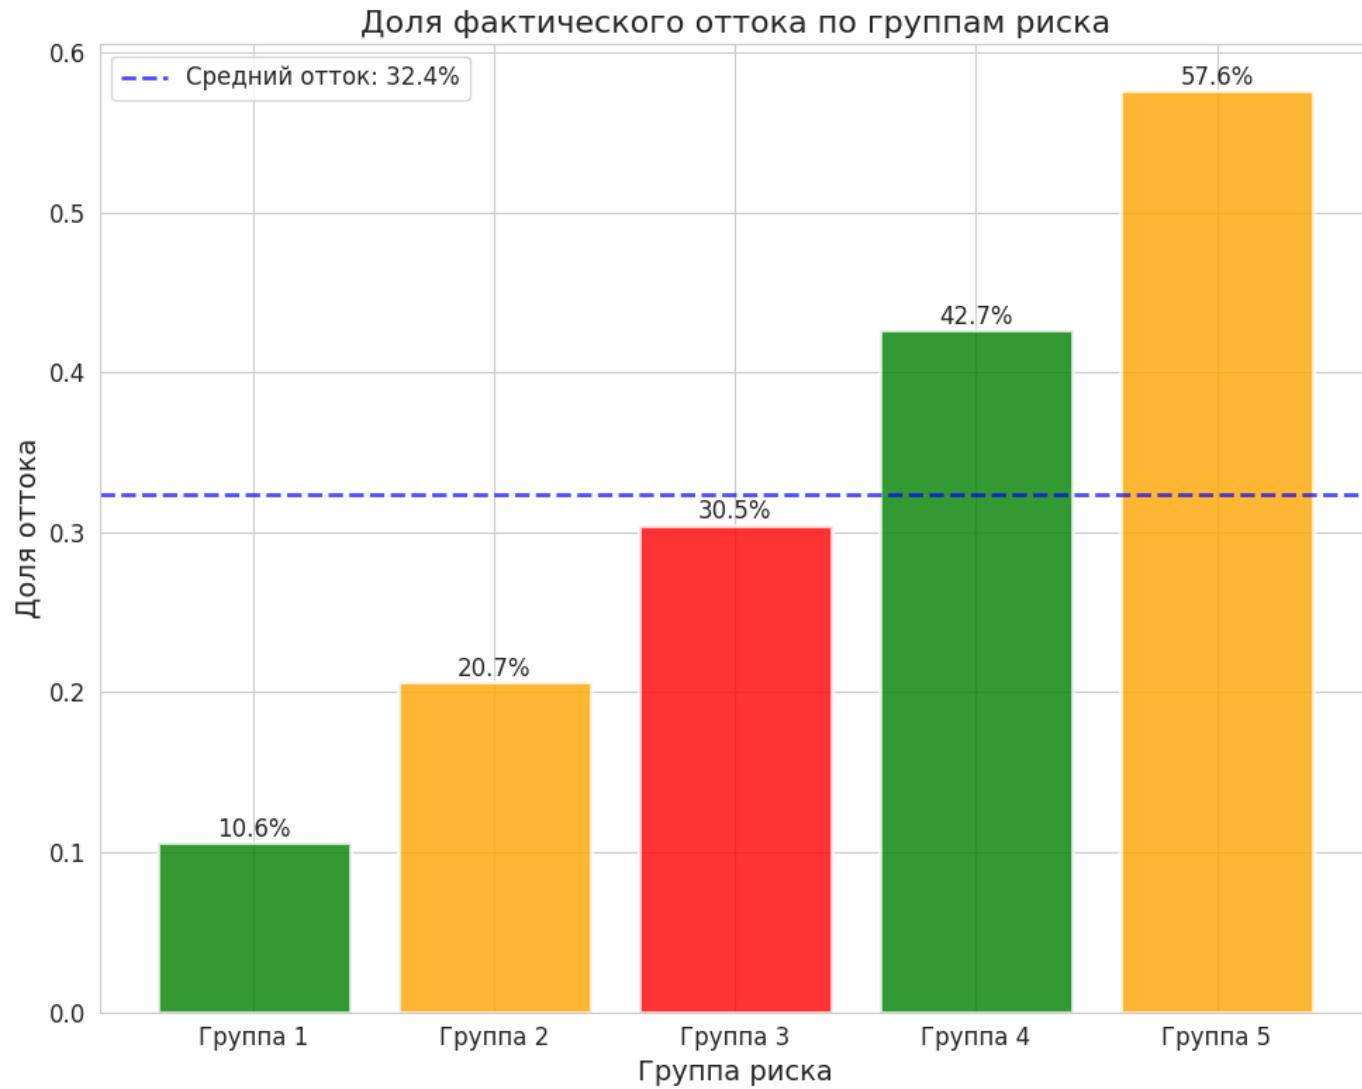
1. Распределение клиентов по группам риска:
Группа 1: 151 клиентов 20.1%
Группа 2: 150 клиентов 19.9%
Группа 3: 151 клиентов 20.1%
Группа 4: 150 клиентов 19.9%
Группа 5: 151 клиентов 20.1%

2. Доля оттока по группам риска:
Группа 1: 10.6% оттока (16 из 151 клиентов)
Группа 2: 20.7% оттока (31 из 150 клиентов)
Группа 3: 30.5% оттока (46 из 151 клиентов)
Группа 4: 42.7% оттока (64 из 150 клиентов)
Группа 5: 57.6% оттока (86 из 151 клиентов)

3. Пороги вероятностей для групп риска:
Группа 1: 0.000 - 0.303
Группа 2: 0.303 - 0.396
Группа 3: 0.396 - 0.512
Группа 4: 0.512 - 0.631
Группа 5: 0.631 - 1.000

ГРУППА 2 (риск низкий)
ХАРАКТЕРИСТИКИ КЛИЕНТА:
Пол: Женщина
Возраст: 36 лет
Кредитный рейтинг: 702
Баланс: 105,264.88
Страна: Франция
Количество продуктов: 2
Стаж в банке: 2 лет
Активный клиент: Да
Есть кредитная карта: Да
Оценочная зарплата: 52,909.87

РЕЗУЛЬТАТЫ ПРОГНОЗИРОВАНИЯ:
Вероятность оттока: 0.359 (35.9%)
Прогноз модели: Останется
Фактический результат: Остался
Результат: Модель правильно спрогнозировала





Заключение

Цель данной курсовой работы — разработать и протестировать сценарий анализа и обработки данных для прогнозирования оттока клиентов банка с использованием логистической регрессии — достигнута.

Основные результаты показывают:

- Анализ данных показал, что наибольший отток наблюдается в Германии, а также среди клиентов старшего возраста с высоким балансом.
- Построена и оценена модель логистической регрессии с L2-регуляризацией, показала хорошие результаты ($F1 = 0.56$, ROC-AUC = 0.72, PR-AUC: 0.53).
- Разработана система скоринга, позволяющая сегментировать клиентов по уровню риска.
- Важные признаки: возраст, баланс, активность клиента, число продуктов.
- Практическая значимость: модель позволяет идентифицировать клиентов с высоким риском оттока и принимать превентивные меры.