

МИНИСТЕРСТВО НАУКИ И ВЫСШЕГО ОБРАЗОВАНИЯ РОССИЙСКОЙ ФЕДЕРАЦИИ
Федеральное государственное бюджетное образовательное учреждение высшего образования
«МИРЭА - Российский технологический университет»
Институт информационных технологий (ИИТ)
Кафедра прикладной математики
Направление «Прикладная математика»
профиль «Анализ данных»

Выпускная квалификационная работа бакалавра на тему:

«Разработка модели оценки стоимости футбольных трансферов»

Автор: студент группы ИМБО-02-22
Ким Кирилл Сергеевич
Руководитель: к.ф.-м.н., доцент кафедры прикладной математики
Даева Софья Георгиевна

Москва 2026

Цель, объект и предмет исследования

Актуальность: Объём трансферного рынка превышает 9 млрд евро в год. Решения о стоимости игроков принимаются на интуиции, что создаёт финансовые риски для клубов.

Цель: Разработать модель машинного обучения для прогнозирования стоимости футбольных трансферов на основе игровой активности и физических характеристик игроков.

Объект исследования — процесс формирования стоимости игроков на рынке трансферов.

Предмет исследования — математическая модель прогнозирования трансферной стоимости.

Задачи исследования

1. Изучить предметную область и ключевые факторы стоимости.
2. Провести обзор существующих решений.
3. Сформулировать задачу, критерии, ограничения.
4. Выполнить сбор, очистку и предобработку данных.
5. Спроектировать новые признаки.
6. Обучить модели с подбором гиперпараметров.
7. Провести сравнительный анализ.
8. Протестировать на реальных трансферах.

Характеристика предметной области

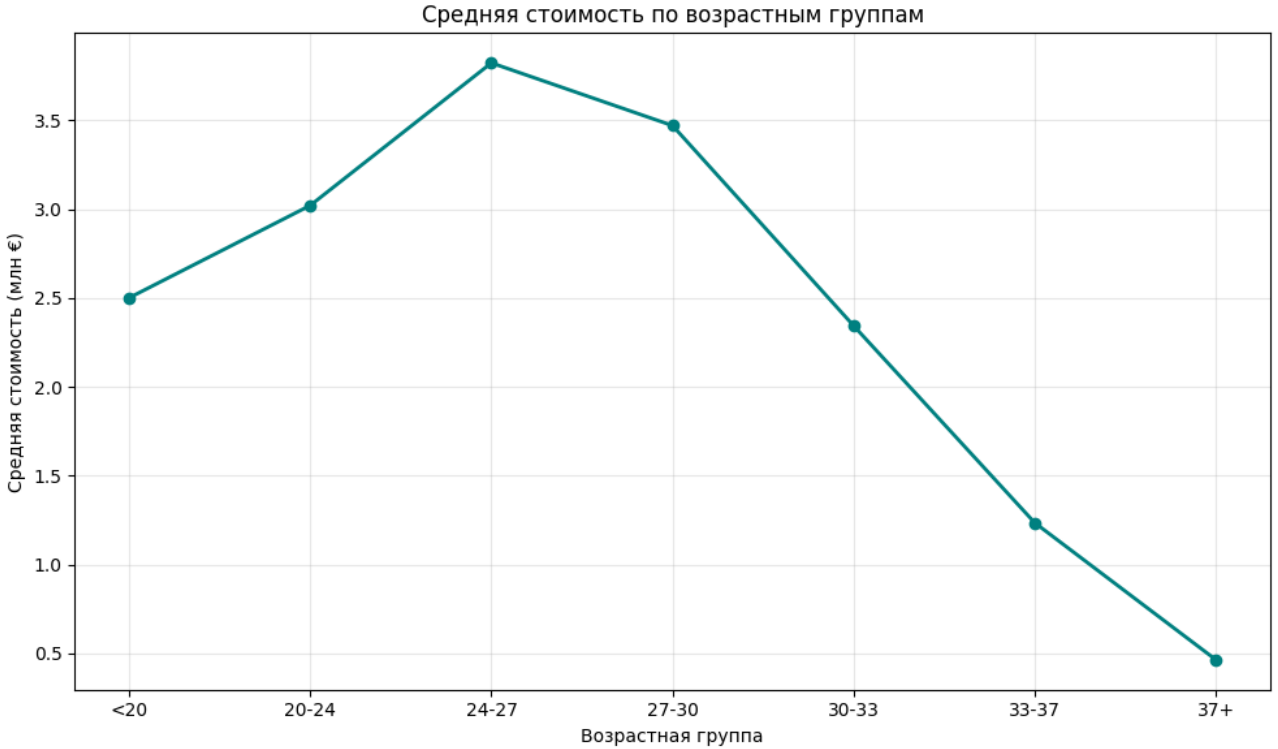


Рисунок 1 — Средняя стоимость по возрастным группам



Рисунок 2 — Динамика стоимости трансферов по сезонам

Цена растет к 24-27 годам, затем снижается.
Факторы стоимости: игровая статистика (голы, передачи), контракт, травмы, рыночные тренды, субъективные факторы.

Обзор существующих решений

Таблица 1 — Существующие решения

Решение	Подход	Недостатки
Transfermarkt	Коллективная экспертная оценка	Субъективность, редкие обновления, ошибки из-за симпатий к клубам
Модели на основе статистики (CIES)	Регрессионый анализ (Используют коэффициенты прошлого опыта)	Не учитывает нелинейности, завышает топ-лиги
Машинное обучение	Random Forest, Gradient Boosting	Нужны большие данные, риск переобучения, настройки гиперпараметров

Целесообразно использовать ML-методы.

Формулировка исследовательской задачи

Постановка задачи:

- Дана выборка: $D = \{(x_i, y_i)\}_{i=1}^{n}$, x_i — признаки игрока, y_i — стоимость трансфера;
- Требуется построить $f: X \to Y$, с минимальной ошибкой.

Разделение метрик:

- Функция потерь при обучении — MSE на логарифмированной стоимости;
- Метрика отбора модели и гиперпараметров — R^2;
- Итоговые метрики качества — MAE (€), R^2, $MAPE$ (%).

Допущения: только открытые данные, только платные трансферы.

Ограничения: модель не учитывает ход переговоров и субъективные факторы.

Анализ и характеристика входных данных

Источник данных — Kaggle, датасет «Football Datasets» (Transfermarkt). 6 таблиц, объём >4 млн. записей.

Таблица 2 — Характеристики исходных таблиц

Название файла	Описание
transfer_history.csv	История трансферов игроков
player_profiles.csv	Профили игроков (дата рождения, позиция и др.)
player_market_value.csv	Динамика рыночной стоимости
player_performances.csv	Детальная игровая статистика по сезонам
player_injuries.csv	Данные о травмах
player_national_performances.csv	Статистика выступлений за сборную

ER-диаграмма

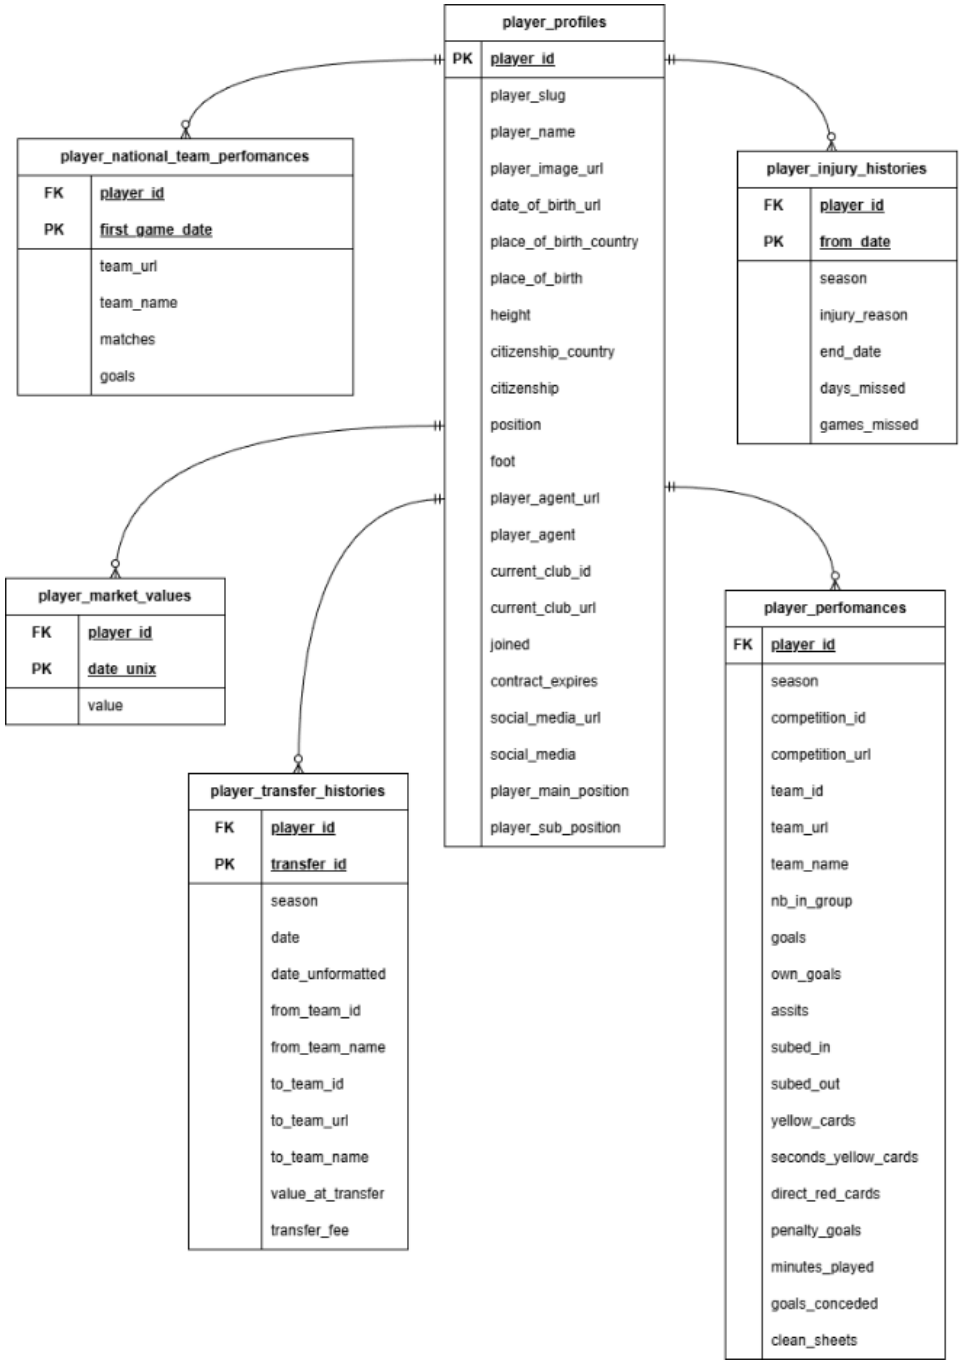


Рисунок 3 — ER-диаграмма исходных таблиц

Описание этапов разработки модели



Обоснование выбора инструментов

Python



Pandas



Numpy



Matplotlib



Scikit-learn



Google Colaboratory



Распределение трансферных сумм

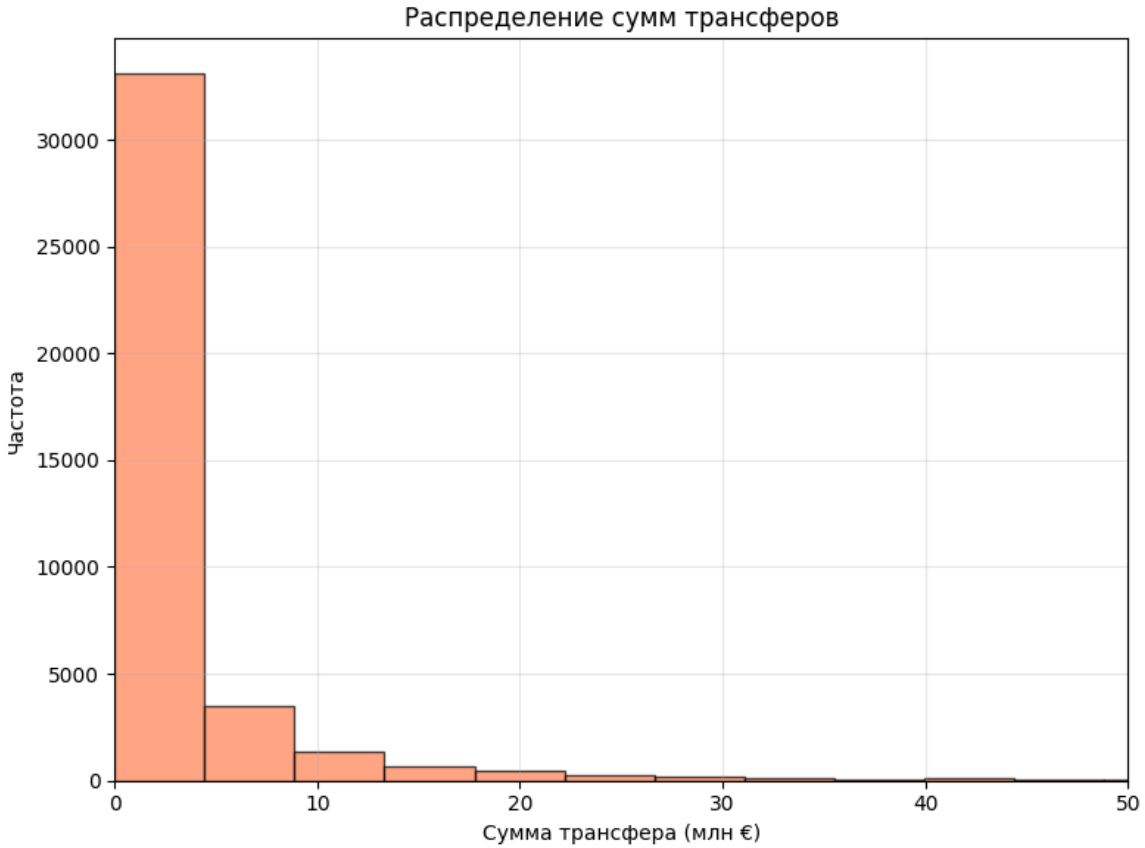


Рисунок 4 — Распределение трансферных сумм

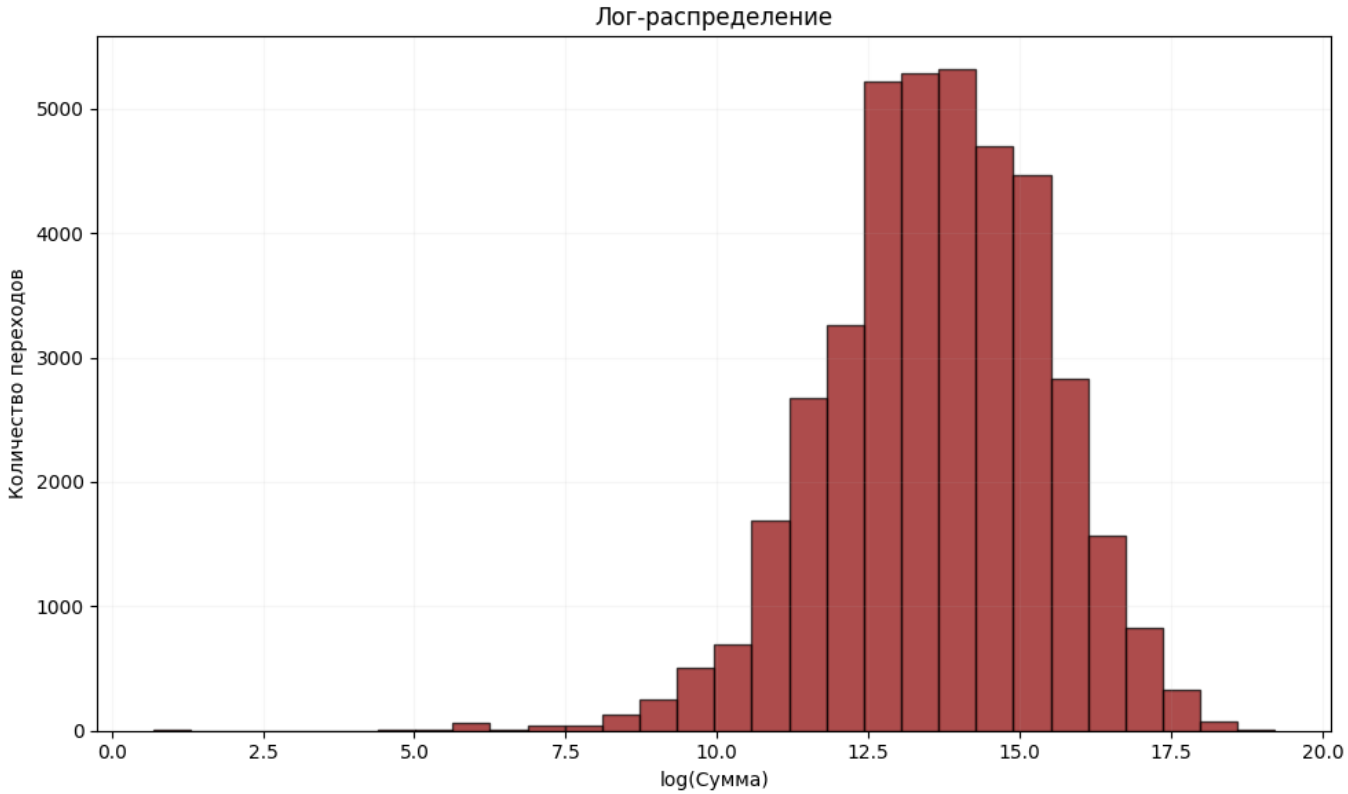


Рисунок 5 — Распределение трансферных сумм после логарифмирования

Обоснование необходимости регуляризации

- Проблема: мультиколлинеарность (корреляция голов и передач ≈ 0,58).
- В обычной линейной регрессии это вызывает нестабильность коэффициентов.
- Решение: Ridge (L2) — сжимает коэффициенты, Lasso (L1) — может обнулять незначимые.

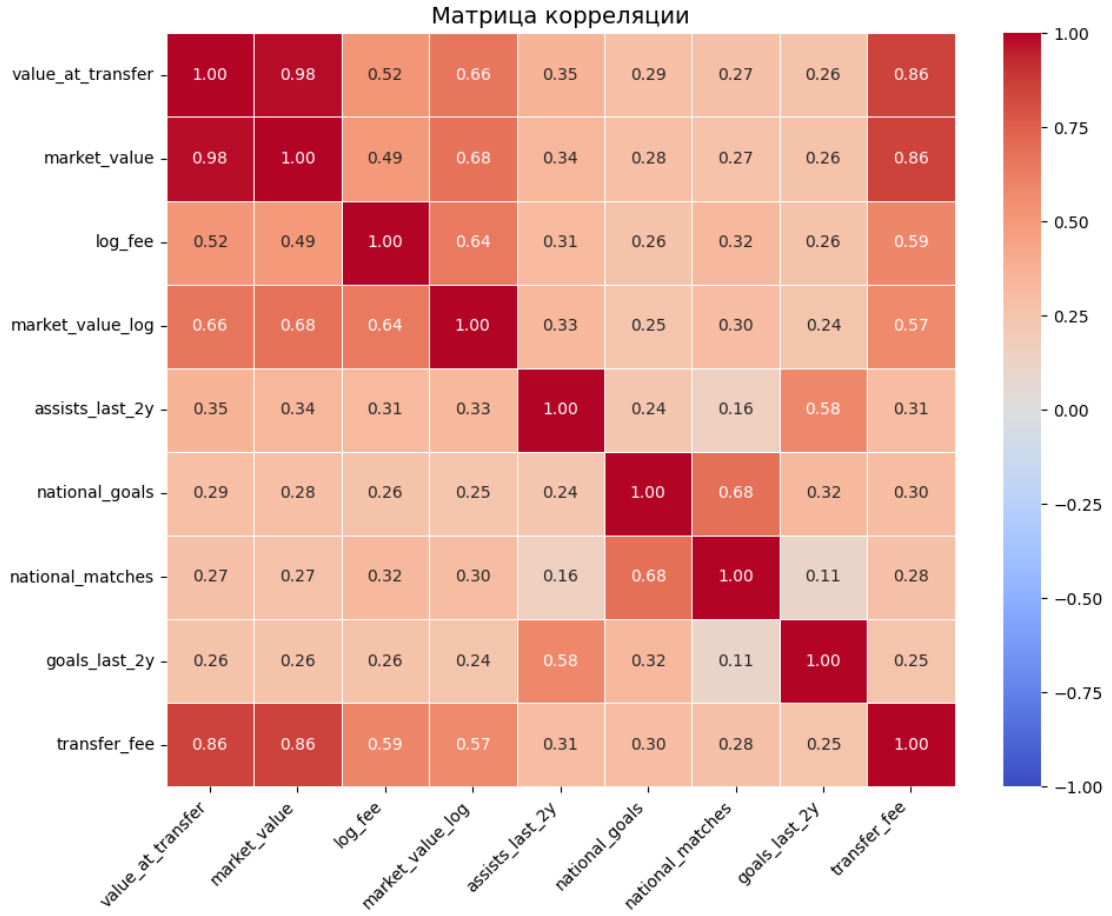


Рисунок 6 — Матрица корреляции

Временная валидация и подбор гиперпараметров

Схема разделения данных:

- Обучение: трансферы до 2021 г. (1973-2021, >30 тыс. записей)
- Тест: трансферы 2022-2026 гг (>9 тыс. записей).

Кросс-валидация: TimeSeriesSplit — обучающая выборка всегда предшествует тестовой, исключая утечку будущей информации.

Подбор гиперпараметров: GridSearchCV.

- Ridge: $\alpha \in \{1;10;50\}$;
- Lasso: $\alpha \in \{0,001;0,01;0,1\}$;
- Random Forest: количество деревьев $\epsilon\{100;200\}$, глубина $\epsilon\{15;20\}$, минимальное число объектов в листе $\epsilon\ \{5;10\}$;
- Gradient Boosting: количество деревьев $\epsilon\{100;200\}$, learning_rate количество деревьев $\epsilon\ \{0,01;0,05\}$, глубина $\epsilon\{3;5\}$;

Реализация модели и анализ результатов

Таблица 3 — Оптимальные гиперпараметры для всех моделей

Модель	Описание
Ridge (L2-регуляризация)	$\alpha = 50$
Lasso (L1-регуляризация)	$\alpha = 0{,}01$
Random Forest	200 деревьев, максимальная глубина 15
Gradient Boosting	100 деревьев, скорость обучения 0,05, глубина 5

```
Обучение: Ridge (L2)
   Train: MAE = €2,338,962, R² = -14.8802, MAPE = 29.3%
   Test : MAE = €3,103,832, R² = -14.3914, MAPE = 41.8%

Обучение: Lasso (L1)
   Train: MAE = €2,239,226, R² = -11.5699, MAPE = 32.3%
   Test : MAE = €2,864,391, R² = -8.1105, MAPE = 39.7%

Обучение: Random Forest
   Train: MAE = €1,101,130, R² = 0.8276, MAPE = 7.5%
   Test : MAE = €1,772,882, R² = 0.7808, MAPE = 42.5%

Обучение: Gradient Boosting
   Train: MAE = €1,423,874, R² = 0.7059, MAPE = 13.7%
   Test : MAE = €1,787,537, R² = 0.7632, MAPE = 49.3%

Лучшая модель на тесте: Random Forest (R² = 0.7808)
```

Рисунок 6 — Сравнение метрик

Важность признаков

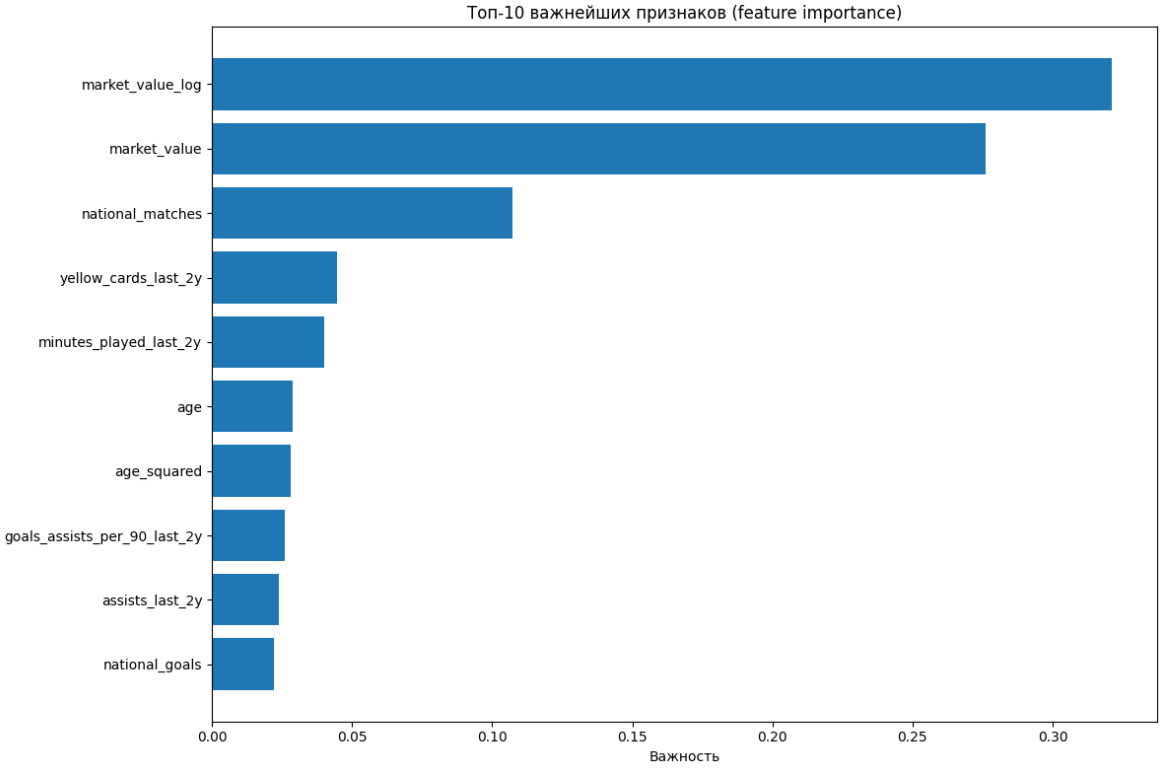


Рисунок 7 — Важность признаков (feature importance)

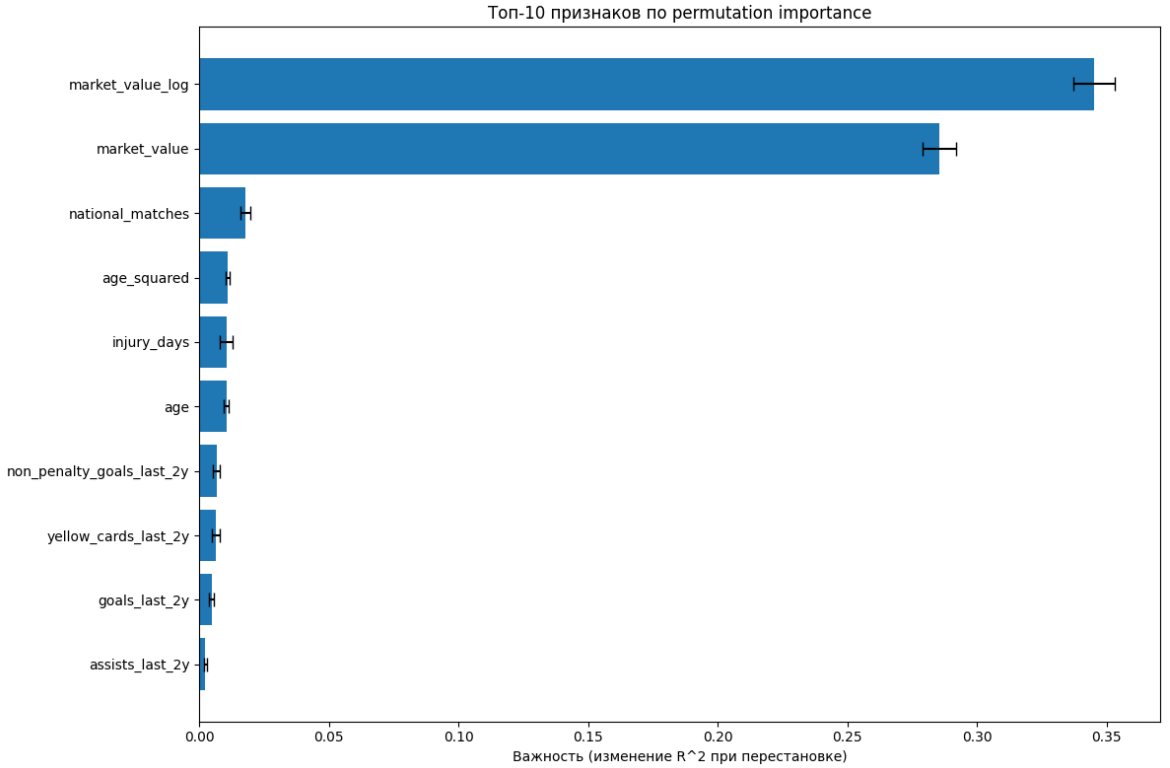


Рисунок 8 — Важность признаков (permutation importance)

Логарифм рыночной стоимости — главный фактор (32,1%).
Permutation importance подтверждает значимость возраста и возраста^2.

Тестирование на реальных трансферах

Таблица 4 — Результаты прогноза для конкретных трансферов

Игрок	Сезон	Фактическая стоимость	Прогноз	Ошибка
Карим Бензема	2009	35 млн. евро	31,9 млн. евро	8,7 %
Златан Ибрагимович	2011	24 млн. евро	22,7 млн. евро	5,4 %
Антуан Гризманн	2019	120 млн. евро	125,2 млн. евро	4,3 %
Луис Суарес	2022	10 млн. евро	9,4 млн. евро	5,7 %
Кристьян Аслани	2023	15,7 млн. евро	13,3 млн. евро	15,3 %
Арнау Тенас	2025	2,5 млн. евро	2,9 млн. евро	14,2 %

Относительная ошибка прогноза на трансферах (Бензема, Гризманн, Суарес и др.) составила от 4,3% до 15,3%, что подтверждает практическую применимость модели.

Заключение

Цель достигнута: разработана модель оценки стоимости футбольных трансферов;

Задачи решены:

- Проанализирована предметная область и выделены ключевые факторы стоимости.
- Проведён обзор существующих решений (Transfermarkt, CIES).
- Сформулирована исследовательская задача, определены метрики и ограничения.
- Выполнены сбор, очистка, предобработка данных и генерация новых признаков.
- Обучены и сравнены 4 модели ML. Лучшая — Random Forest ($R^2 = 0{,}7808$, $MAE = 1{,}773$ млн €).
- Модель протестирована на реальных трансферах (ошибка 4,3% – 15,3%);

Подтверждена практическая применимость.

Видеопрезентация работы



Рисунок 9 — QR-код

Благодарю за внимание!



МИНИСТЕРСТВО НАУКИ И ВЫСШЕГО ОБРАЗОВАНИЯ РОССИЙСКОЙ ФЕДЕРАЦИИ
Федеральное государственное бюджетное образовательное учреждение высшего образования
«МИРЭА - Российский технологический университет»
Институт информационных технологий (ИИТ)
Кафедра прикладной математики
Направление «Прикладная математика»
профиль «Анализ данных»

Выпускная квалификационная работа бакалавра на тему:

«Разработка модели оценки стоимости футбольных трансферов»

Автор: студент группы ИМБО-02-22
Ким Кирилл Сергеевич
Руководитель: к.ф.-м.н., доцент кафедры прикладной математики
Даева Софья Георгиевна

Москва 2026