



МИНИСТЕРСТВО НАУКИ И ВЫСШЕГО ОБРАЗОВАНИЯ РОССИЙСКОЙ ФЕДЕРАЦИИ
Федеральное государственное бюджетное образовательное учреждение высшего образования

«МИРЭА - Российский технологический университет»

Институт информационных технологий (ИИТ)

Кафедра прикладной математики

Направление «Прикладная математика»

профиль «Анализ данных»

Выпускная квалификационная работа бакалавра на тему:
«Разработка модели оценки стоимости футбольных трансферов»

Автор: студент группы ИМБО-02-22

Ким Кирилл Сергеевич

Руководитель: к.ф.-м.н., доцент кафедры прикладной математики

Даева Софья Георгиевна

Москва 2026

Цель, объект и предмет исследования

Актуальность: Объём трансферного рынка превышает 7 млрд евро в год. Решения о стоимости игроков принимаются на интуиции, что создаёт финансовые риски.

Цель: Разработать модель машинного обучения для прогнозирования стоимости футбольных трансферов на основе игровой активности и физических характеристик игроков.

Объект исследования — процесс формирования стоимости игроков на рынке трансферов.

Предмет исследования — математическая модель прогнозирования трансферной стоимости.

Задачи исследования

1. Изучить предметную область и ключевые факторы стоимости.
2. Провести обзор существующих решений.
3. Сформулировать задачу, критерии, ограничения.
4. Выполнить сбор, очистку и предобработку данных.
5. Спроектировать новые признаки.
6. Обучить модели с подбором гиперпараметров.
7. Провести сравнительный анализ.
8. Протестировать на реальных трансферах.

Характеристика предметной области




Рисунок 1 — Средняя стоимость по возрастным группам




Рисунок 2 — Динамика стоимости трансферов по сезонам

Пик стоимости 26–29 лет.

Факторы стоимости: игровая статистика (голы, передачи), контракт, травмы, рыночные тренды, субъективные факторы.

Обзор существующих решений

Таблица 1 — Существующие решения

Решение	Подход	Недостатки
Transfermarkt	Коллективная экспертная оценка	Субъективность, редкие обновления, ошибки из-за симпатий к клубам.
Модели на основе статистики (CIES)	Регрессионный анализ (Используют коэффициенты прошлого опыта)	Не учитывает нелинейности, завышает топ-лиги
Машинное обучение	Random Forest, Gradient Boosting	Нужны большие данные, риск переобучения, настройки гиперпараметров

Transfermarkt субъективен и редок, CIES линеен и недоступен. Целесообразно использовать ML-методы.

Формулировка исследовательской задачи

Постановка задачи:

- Дана выборка: $D = \{(x_i, y_i)\}_{i=1}^n$, x_i — признаки игрока, y_i — стоимость трансфера;
- Требуется построить $f: X \rightarrow Y$, с минимальной ошибкой.

Метрики:

- MAE (средняя абсолютная ошибка) $\approx 3,0$ млн евро;
- R^2 (коэффициент детерминации) $\geq 0,5$;
- $MARE$ (средняя абсолютная процентная ошибка) $\leq 50\%$.

Допущения: только открытые данные, только платные трансферы.

Ограничения: модель не учитывает ход переговоров и субъективные факторы.

Анализ и характеристика входных данных

Источник данных — Kaggle, датасет «Football Datasets» (Transfermarkt). 6 таблиц, объём >4 млн. записей.

Таблица 2 — Характеристики исходных таблиц

Название файла	Описание
transfer_history.csv	История трансферов игроков
player_profiles.csv	Профили игроков (дата рождения, позиция и др.)
player_market_value.csv	Динамика рыночной стоимости
player_performances.csv	Детальная игровая статистика по сезонам
player_injuries.csv	Данные о травмах
player_national_performances.csv	Статистика выступлений за сборную

ER-диаграмма





Рисунок 3 — ER-диаграмма исходных таблиц

Описание этапов разработки модели



Обоснование выбора инструментов

Python



Pandas



Numpy



Matplotlib



Scikit-learn



Google Colaboratory



Распределение трансферных сумм




Рисунок 4 — Распределение трансферных сумм




Рисунок 5 — Распределение трансферных сумм после логарифмирования

Реализация модели и анализ результатов

Подбор через GridSearchCV с TimeSeriesSplit

Таблица 3 — Оптимальные гиперпараметры для всех моделей

Модель	Описание
Ridge (L2-регуляризация)	$\alpha = 50$
Lasso (L1-регуляризация)	$\alpha = 0,01$
Random Forest	200 деревьев, максимальная глубина 15
Gradient Boosting	100 деревьев, скорость обучения 0,05, глубина 5

Обучение: Ridge (L2)

Train: MAE = €2,338,962, $R^2 = -14.8802$, MAPE = 29.3%

Test : MAE = €3,103,832, $R^2 = -14.3914$, MAPE = 41.8%

Обучение: Lasso (L1)

Train: MAE = €2,239,226, $R^2 = -11.5699$, MAPE = 32.3%

Test : MAE = €2,864,391, $R^2 = -8.1105$, MAPE = 39.7%

Обучение: Random Forest

Train: MAE = €1,101,130, $R^2 = 0.8276$, MAPE = 7.5%

Test : MAE = €1,772,882, $R^2 = 0.7808$, MAPE = 42.5%

Обучение: Gradient Boosting

Train: MAE = €1,423,874, $R^2 = 0.7059$, MAPE = 13.7%

Test : MAE = €1,787,537, $R^2 = 0.7632$, MAPE = 49.3%

Лучшая модель на тесте: Random Forest ($R^2 = 0.7808$)

Рисунок 6 — Сравнение метрик

Важность признаков




Рисунок 7 — Анализ важных признаков




Рисунок 8 — Анализ важных признаков по permutation

Логарифм рыночная стоимость — главный фактор (32,1%).

Permutation importance подтверждает значимость возраст и возраст².

Тестирование на реальных трансферах

Таблица 4 — Результаты прогноза для конкретных трансферов

Игрок	Сезон	Фактическая стоимость	Прогноз	Ошибка
Карим Бензема	2009	35 млн. евро	31,9 млн. Евро	8,7 %
Златан Ибрагимович	2011	24 млн. евро	22,7 млн. Евро	5,4 %
Антуан Гризманн	2019	120 млн. евро	125,2 млн. Евро	4,3 %
Луис Суарес	2022	10 млн. евро	9,4 млн. Евро	5,7 %
Кристъян Аслани	2023	15,7 млн. евро	13,3 млн. Евро	15,3 %
Арнау Тенас	2025	2,5 млн. евро	2,9 млн. евро	14,2 %

Относительная ошибка прогноза на трансферах (Бензема, Гризманн, Суарес и др.) составила от 4,3% до 15,3%, что подтверждает практическую применимость модели.

Заключение

Цель достигнута: разработана модель оценки стоимости футбольных трансферов;

Задачи решены:

- Проанализирована предметная область и выделены ключевые факторы стоимости.
- Проведён обзор существующих решений (Transfermarkt, CIES).
- Сформулирована исследовательская задача, определены метрики и ограничения.
- Выполнены сбор, очистка, предобработка данных и генерация новых признаков.
- Обучены и сравнены 4 модели ML. Лучшая — Random Forest ($R^2 = 0,7808$, $MAE = 1,773$ млн €).
- Модель протестирована на реальных трансферах (ошибка 4,3% – 15,3%);

Подтверждена практическая применимость;

Благодарю за внимание!